

# Technologie obiektowe: Laboratorium 5

Piotr Szuster

9 grudnia 2024

## 1 Śledzenie obiektów w przestrzeni dwuwymiarowej

W 2024 na świecie toczy się wiele konfliktów zbrojnych. Trwa agresja zbrojna Rosji na Ukrainę podczas której agresor używa przeciwko Ukrainie środków napadu powietrznego takich jak bezzałogowe statki powietrzne, pociski manewrujące oraz pociski balistyczne. 1 października 2024 Iran użył rakiet balistycznych przeciwko Izraelowi.

Wykrycie, identyfikacja oraz śledzenie zagrożeń podczas ataku z użyciem środków napadu powietrznego stanowi znaczące wyzwanie z punktu widzenia obrony przeciwlotniczej/antybalistycznej.

Aby zidentyfikować nadlatujące obiekty wykorzystuje się między innymi radary, które emitują fale elektromagnetyczne. Fale elektromagnetyczne, emitowane przez radar ulegają odbiciu od poruszającego się obiektu i są rejestrowane jako echo. Ciągi ech radarowych można rozpatrywać jako szeregi czasowe detekcji, grupować w ścieżki przez co można wyznaczyć trajektorię, prędkość i kierunek przemieszczania się obiektów.

Rozważmy uproszczony model, zakładający śledzenie obiektów w przestrzeń dwuwymiarowej. W tym modelu symulowany sygnał z radaru jest rzutowany na płaszczyznę i składa się z pikseli. Każdemu pikselowi przyporządkowano wartość z zakresu 0-255, proporcjonalną do mocy odbitego od obiektu sygnału. Przykład jest widoczny na rysunku 1.

Można zauważać, że na przeważającym obszarze obrazu widoczny jest szum, powodowany przez obecność zakłóceń. Wnikliwy obserwator jest w stanie dostrzec dwa jasne obszary, które wyróżniają się na tle pozostałoego obrazu radarowego. Obszary te zaznaczono na rysunku 2. Aby wyodrębnić echo radarowe z tego typu obrazu należy podzielić piksele na dwie klasy: echo obiektu, tło. Do wykonania tej operacji w kontekście realizowanego laboratorium można posłużyć relatywnie prostą w implementacji metodą Otsu.

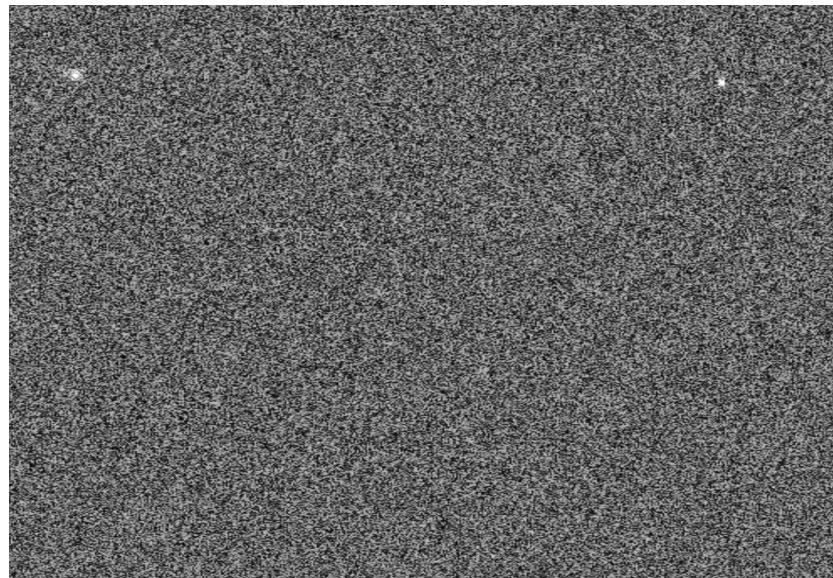
### 1.1 Metoda Otsu

Metoda Otsu to efektywna technika stosowana w przetwarzaniu obrazów do automatycznego wyznaczania optymalnego progu w procesie segmentacji obrazów, szczególnie przy binaryzacji obrazów.

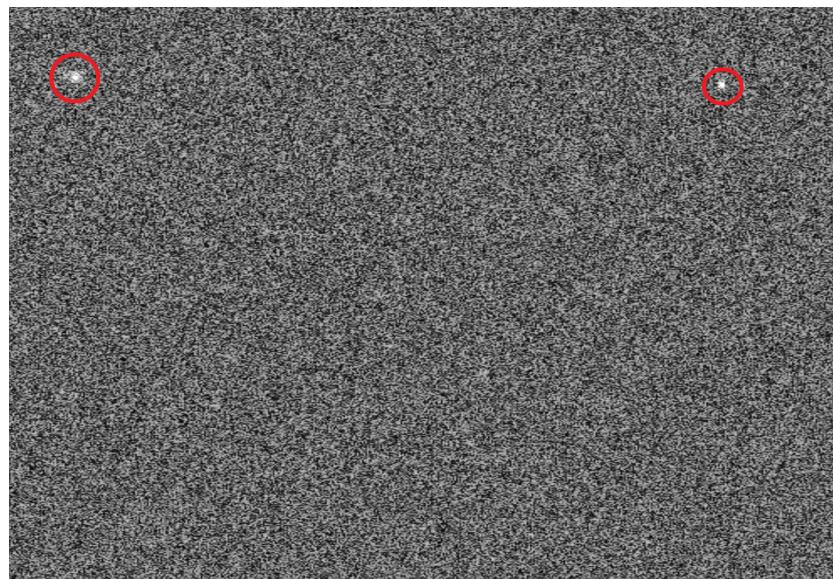
Metoda Otsu wykorzystuje analizę histogramu jasności obrazu i polega na wyznaczeniu progu, który minimalizuje wariancję wewnętrzklasową lub, równoważnie, maksymalizuje wariancję międzyklasową. Optymalny próg dzieli piksele na dwie klasy – tło i obiekt – tak, aby te dwie klasy były jak najbardziej jednorodne.

Kroki działania metody Otsu:

- Obliczenie histogramu – liczba pikseli dla każdej wartości jasności (najczęściej od 0 do 255).
- Normalizacja histogramu – przekształcenie liczby pikseli w prawdopodobieństwo wystąpienia danej wartości jasności.
- Iteracyjne próby podziału – dla każdej możliwej wartości progu  $t$ :
  - Oblicz prawdopodobieństwo wystąpienia klas (pikseli poniżej i powyżej progu).
  - Oblicz średnią jasność dla obu klas. Wyznacz wariancję wewnętrzklasową i międzyklasową.
  - Wybór optymalnego progu – próg, który minimalizuje wariancję wewnętrzklasową lub maksymalizuje wariancję międzyklasową.



Rysunek 1: Wizualizacja przykładowego sygnału radarowego.



Rysunek 2: Wizualizacja przykładowego sygnału radarowego. Obszary ech zaznaczono czerwonymi okręgami.



Rysunek 3: Wizualizacja przykładowego sygnału radarowego po podziale na 2 klasy metodą Otsu. Białe piksele są sklasyfikowane jako detekcja obiektu, czarne jako tło.

Wzory wykorzystywane w metodzie Otsu:

**Prawdopodobieństwo wystąpienia pikseli dla klas:**

$$\omega_1(t) = \sum_{i=0}^t p(i), \quad \omega_2(t) = \sum_{i=t+1}^{L-1} p(i)$$

**Średnie wartości dla obu klas:**

$$\mu_1(t) = \frac{\sum_{i=0}^t i \cdot p(i)}{\omega_1(t)}, \quad \mu_2(t) = \frac{\sum_{i=t+1}^{L-1} i \cdot p(i)}{\omega_2(t)}$$

**Wariancja wewnętrzklasowa:**

$$\sigma_w^2(t) = \omega_1(t)\sigma_1^2(t) + \omega_2(t)\sigma_2^2(t)$$

**Wariancja międzyklasowa:**

$$\sigma_b^2(t) = \omega_1(t)\omega_2(t)(\mu_1(t) - \mu_2(t))^2$$

Przykładowy sygnał radarowy po podziale na klasy metodą Otsu jest widoczny na rysunku 3.

Aby wyodrębnić detekcje obiektów należy białe piksele pogrupować w spójne zbiory stosując kryterium sąsiedztwa (odległość od siebie).

## 1.2 Wyodrębnianie blobów

Wyodrębnianie sąsiednich pikseli o tym samym kolorze to proces nazywany segmentacją obszarów (ang. region growing) lub znajdowaniem spójnych komponentów (ang. connected component labeling). W przypadku tego zadania stosuje się algorytm, które grupują piksele na podstawie podobieństwa ich wartości oraz sąsiedztwa. Algorytm **Connected Component Labelling** (CCL) służy do identyfikacji i oznaczania spójnych obszarów (tzw. blobów) w obrazach binarnych lub wielopoziomowych. Każdemu spójnemu regionowi składającemu się z sąsiednich pikseli o tej samej wartości przypisywana jest unikalna etykieta.

## Podstawowe Pojęcia

- **Spójność** – piksele należą do tej samej komponenty, jeśli sąsiadują ze sobą:
  - \* **4-sąsiedztwo** – sąsiadzi położeni w góre, dół, lewo i prawo.
  - \* **8-sąsiedztwo** – dodatkowo sąsiadzi na skos.
- **Obraz binarny** – obraz składający się z dwóch wartości (np. 0 i 1), gdzie 1 oznacza piksel należący do obiektu, a 0 oznacza tło.

## Kroki Algorytmu

Algorytm działa w dwóch głównych etapach:

### 1. Pierwsze przejście (First Pass):

- Przeglądaj piksele obrazu wiersz po wierszu.
- Jeśli piksel należy do obiektu (np. ma wartość 1):
  - \* Sprawdź sąsiadów (lewego, górnego w 4-sąsiedztwie lub dodatkowo skosy w 8-sąsiedztwie).
  - \* Przypisz pikselowi etykietę sąsiada lub nową etykietę, jeśli sąsiadzi nie mają etykiet.
  - \* Zapisz konflikty, jeśli sąsiadzi mają różne etykiety.

### 2. Rozwiązywanie konfliktów (Label Equivalence Resolution):

- Utwórz strukturę danych do przechowywania relacji równoważności etykiet.
- Po zakończeniu pierwszego przejścia przekształć wszystkie etykietę w ich ostateczne wartości.

### 3. Drugie przejście (Second Pass):

- Zaktualizuj etykietę pikseli na podstawie ostatecznej mapy etykiet.

Posiadając wyodrębnione błyby należy określić wartości średnich arytmetycznych współrzędnych  $x$  oraz  $y$  pikseli, które wchodzą w ich skład oraz odchylenia standardowe. Pozwoli to zdefiniować rozkład prawdopodobieństwa położenia obiektu w danym zobrazowaniu radarowym. Za rozkład prawdopodobieństwa położenia należy przyjąć rozkład normalny.

### 1.3 Rozkład normalny

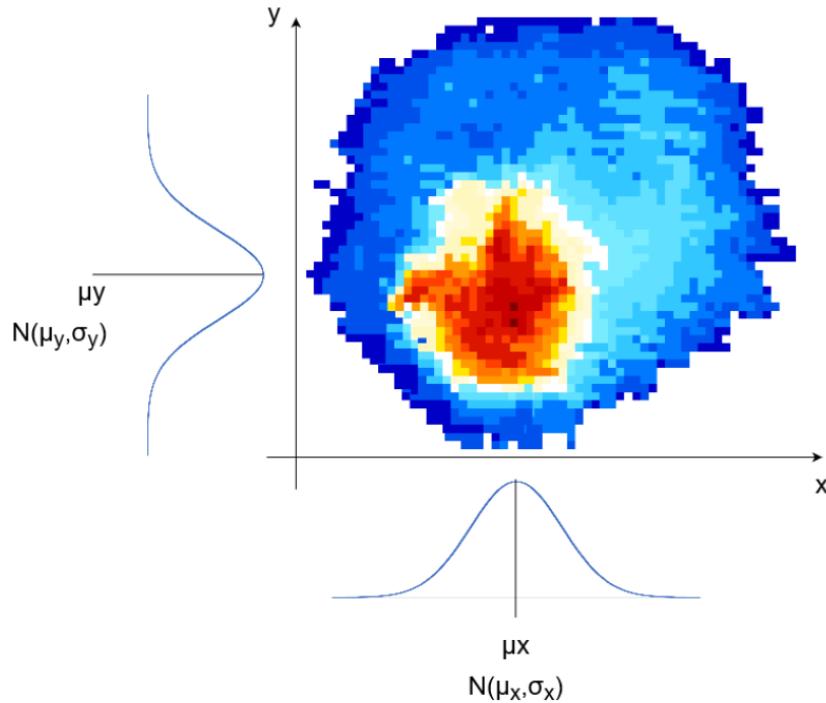
Rozkład normalny, znany również jako rozkład Gaussa, to jeden z najważniejszych rozkładów w statystyce. Rozkład normalny o średniej  $\mu$  i odchyleniu standardowym  $\sigma$  opisuje funkcja gęstości prawdopodobieństwa:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad (1)$$

gdzie:

- $\mu$  – średnia rozkładu (wartość oczekiwana),
- $\sigma$  – odchylenie standardowe,
- $\pi$  – liczba pi,  $\pi \approx 3.14159$ ,
- $\exp(x)$  – funkcja wykładnicza,  $\exp(x) = e^x$ , gdzie  $e \approx 2.71828$ .

Dla każdej współrzędnej Bloba należy określić rozkład prawdopodobieństwa. Przykładowy rysunek ilustrujący rozkłady jest umieszczony tutaj: [4](#).



Rysunek 4: Rysunek poglądowy przedstawiający reprezentację rozkładów prawdopodobieństwa współrzędnych Bloba.

#### 1.4 Śledzenie wielu hipotez

Śledzenie wielu hipotez (MHT) to metoda wykorzystywana w systemach śledzenia obiektów, które są podatne na zakłócenia, błędy pomiarowe oraz niepewność w przypisywaniu pomiarów do celów. Główna idea MHT polega na śledzeniu wielu możliwych scenariuszy (hipotez) przypisania pomiarów do obiektów w danym czasie, a następnie ocenianiu, które z tych hipotez są najbardziej prawdopodobne.

W systemach śledzenia obiektów często występują problemy z niejednoznacznością przypisania pomiarów do obiektów, zwłaszcza w sytuacjach, gdy obiekty są blisko siebie, a pomiary są zakłócone przez szum. W takich warunkach MHT umożliwia:

1. Tworzenie wielu hipotez: Algorytm tworzy wiele możliwych scenariuszy, zakładając różne przypisania pomiarów do celów. Dla każdego pomiaru w danym czasie, przypisania mogą obejmować zarówno przypisanie do istniejącego celu, jak i uznanie pomiaru za zakłócenie.
2. Rozbudowę hipotez w czasie: Z każdą nową porcją pomiarów system rozbudowuje dotychczasowe hipotezy, biorąc pod uwagę nowe dane.
3. Ocena prawdopodobieństwa: Każda hipoteza jest oceniana na podstawie jej prawdopodobieństwa. To prawdopodobieństwo może być obliczane na podstawie założeń o modelach ruchu obiektów, danych pomiarowych, a także modelach zakłóceń.
4. Wybór najbardziej prawdopodobnej hipotezy: Po analizie wielu hipotez, system wybiera najbardziej prawdopodobną hipotezę i przechodzi do kolejnego kroku śledzenia.

Cechy:

1. Hipotezy: Każda hipoteza reprezentuje różne przypisanie pomiarów do celów. Przykładami hipotez mogą być: zestawienie pomiarów z jednym celem, pomiar z przypisaniem do dwóch różnych celów, uznanie pomiaru za zakłócenie.
2. Model Ruchu: W MHT wykorzystywany jest model ruchu, który prognozuje pozycję i predkość obiektów na podstawie poprzednich stanów.

3. Prawdopodobieństwo: Każda hipoteza jest oceniana na podstawie prawdopodobieństwa, które uwzględnia jakość pomiarów, rozbieżności między prognozowanymi a rzeczywistymi pozycjami obiektów, a także obecność zakłóceń.
4. Przypisanie Pomiary: Na każdym etapie system rozważa, które pomiary należy przypisać do istniejących celów, a które należy uznać za zakłócenia.

Kroki algorytmu:

1. Inicjalizacja: Na początku śledzenia, dla każdego nowego pomiaru, algorytm generuje hipotezy przypisania tego pomiaru do różnych celów lub uznania go za zakłócenie.
2. Przewidywanie: Następnie, bazując na poprzednich stanach celów i zastosowanych modelach ruchu, algorytm przewiduje, gdzie powinny znaleźć się cele w kolejnym czasie.
3. Przypisanie Pomiary do Hipotez: Kolejne pomiary są porównywane z przewidywanymi stanami celów w celu określenia, do której hipotezy dany pomiar najlepiej pasuje. System musi uwzględnić wszystkie możliwe scenariusze przypisania.
4. Rozwój Hipotez: Dla każdej z hipotez, na podstawie przypisanych pomiarów, oblicza się nowe stany i rozwija hipotezy. Każda hipoteza może prowadzić do różnych rozgałęzień w kolejnym czasie.
5. Ocena Prawdopodobieństwa: Każda hipoteza jest oceniana na podstawie prawdopodobieństwa, które jest obliczane na podstawie dopasowania pomiarów do modelu (np. za pomocą funkcji prawdopodobieństwa lub filtrów takich jak filtr Kalmana).
6. Wybór Najbardziej Prawdopodobnej Hipotezy: Na koniec każdej iteracji MHT wybiera hipotezę o najwyższym prawdopodobieństwie, aby kontynuować śledzenie.
7. Rewizja i Odrzucenie Hipotez: W miarę postępu śledzenia, mniej prawdopodobne hipotezy są odrzucane, a system koncentruje się na najbardziej obiecujących.

#### Przykład Zastosowania

Załóżmy, że mamy radar śledzący trzy cele: T1T1, T2T2 i T3T3, a otrzymujemy pięć pomiarów. Możliwe scenariusze przypisania pomiarów mogą obejmować:

Przypisanie jednego pomiaru do jednego celu. Przypisanie jednego pomiaru do dwóch celów. Uznać jeden z pomiarów za zakłócenie.

Dzięki MHT, system tworzy hipotezy, które obejmują różne kombinacje przypisań pomiarów i celów, oraz ocenia, która z tych hipotez jest najbardziej prawdopodobna w danym czasie. W miarę jak nowe pomiary napływają, MHT rozwija te hipotezy i odrzuca mało prawdopodobne scenariusze.

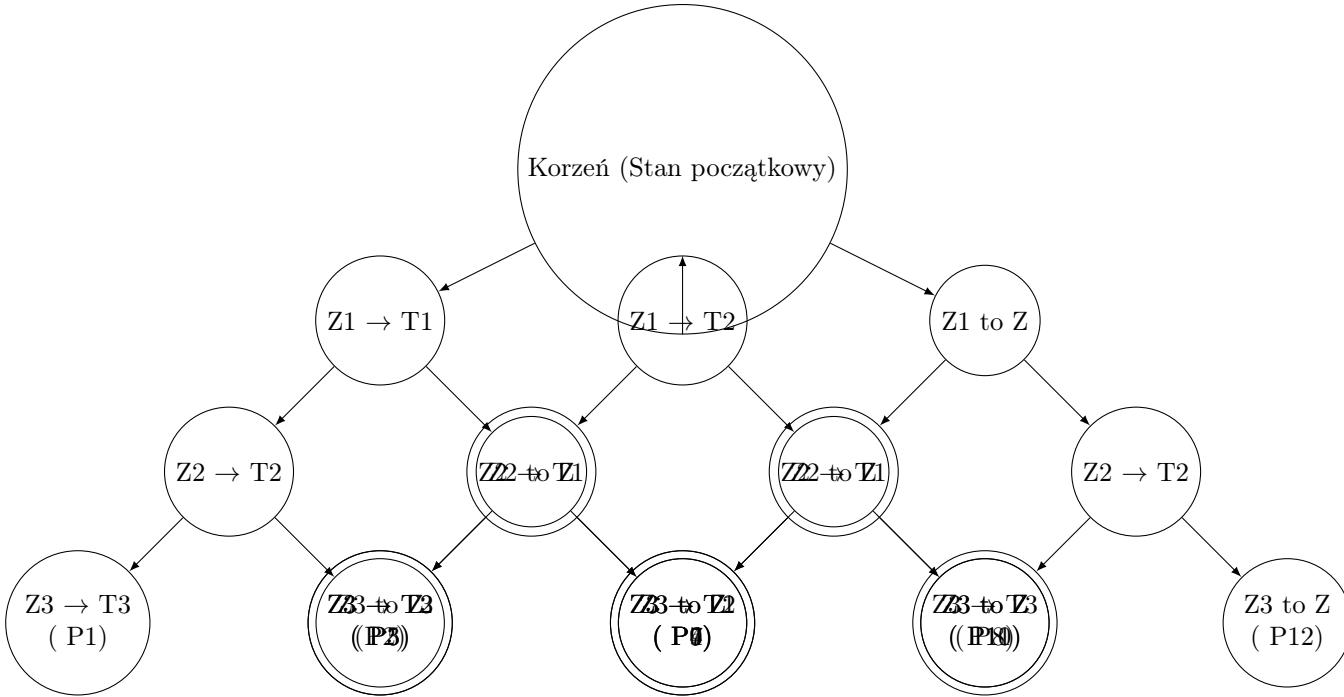
## 1.5 Drzewo asocjacji probabilistycznej

Drzewo asocjacji probabilistycznej to struktura danych wykorzystywana w systemach śledzenia wielocelowego, która pomaga zarządzać wieloma możliwymi przyporządkowaniami pomiarów do celów. Technika ta umożliwia rozważanie różnych scenariuszy przypisania, uwzględniając niepewności związane z pomiarami i zakłóceniami.

Drzewa asocjacji probabilistycznej są szczególnie przydatne w algorytmach takich jak JPDA (Joint Probabilistic Data Association).

- Korzeń drzewa reprezentuje stan początkowy systemu śledzenia, czyli stan śledzonych obiektów przed otrzymaniem nowych pomiarów.
- Węzły drzewa reprezentują różne możliwe przypisania pomiarów do celów lub zakłóceń:
- Każdy węzeł odpowiada jednej możliwości przyporządkowania pomiaru do konkretnego celu.
- Węzły są powiązane z prawdopodobieństwem reprezentującym stopień wiary w dane przypisanie.
- Liście drzewa reprezentują wszystkie możliwe kombinacje przyporządkowań dla zestawu pomiarów.

- Krawędzie drzewa łączą węzły i reprezentują przejścia między kolejnymi poziomami przy porządkowań.



## 1.6 Zadanie

- Zaimplementować program umożliwiający śledzenie położenia wielu obiektów na płaszczyźnie 2D.
- Utworzyć generator danych testowych (szum losowy + symulowane odbicia obiektów)
- Wykorzystać metodę Otsu do progowania. Zmodyfikować uzyskiwany próg.
- Oszacować przydatność algorytmu CCL. W razie potrzeby zmodyfikować jego działanie.
- Wykorzystać drzewo asocjacji probabilistycznej.
- Przedstawić wyniki w formie interaktywnej symulacji.
- Przy jakich liczbach obiektów rozwiązanie ulega wysyceniu?